

꿈	꾸	는	★
★	라	이	언

핵심 요약 노트

데이터 분석 전문가



목 차

1. 데이터 이해	1
2. 데이터 분석 기획	3
3. 데이터 분석	6




■ 데이터: 추론과 추정 근거를 이루는 사실 (사전적 정의)

상호관계 속에서 가치를 가질 수 있으며 추정, 예측을 위한 근거 자료

데이터 (Qualitative Data)	. 비정형 데이터, 저장/분석 등 자료 처리에 많은 비용/시간 소요 Ex. 주관식 응답 / 기상특보 / SNS 텍스트
데이터 (Quantitative Data)	. 수치 기반의 정형 데이터, 많은 자료 양에도 저장/분석 용이 Ex. 온도, 습도, 강우량, 풍속

■ 지식 경영: 개인의 암묵지와 집단의 형식지 간에 상호 작용(생성/발전/전환)을 통해 지식의 발전을 기반으로 한 기업의 경영

	경험과 학습을 통해 개인에게 습득된 무형의 지식으로 공유 어려움 ex. 자동차 운전, 강연, 운동
	구체적이거나 문서화된 지식으로 전달 및 공유 용이 ex. 작업 매뉴얼, 설계도, 데이터베이스, 프로그램



■ DIKW 피라미드: 데이터, 정보, 지식을 통해 최종적으로 지혜를 얻어내는 일련의 과정을 나타내는 계층구조

- . D: 가공 전의 객관적인 사실 및 단순한 수치/기호
→ *A마트는 100원에, B마트는 300원에 연필을 판매한다.*
- . I: 데이터 가공 및 상관관계 속에서 패턴을 인식하고 의미를 도출
→ *A마트의 연필이 B마트보다 싸다.*
- . K: 상호 연결된 정보 패턴을 이해하여 이를 토대로 예측한 결과물
→ *상대적으로 저렴한 A마트에서 연필을 사야겠다.*
- . W: 근본 원리에 대한 깊은 이해를 바탕으로 도출되는 창의적 아이디어
→ *다른 상품들도 A마트가 B마트보다 저렴할 것이라 판단한다.*

■ 데이터베이스 4가지 특징

- . 중복: 데이터베이스 내 중복된 데이터 없음 (**중복 최소화**)
- . 접근: 컴퓨터가 **접근 가능한 저장 매체**에 데이터 저장 가능
- . 공유: 여러 사용자가 동일 데이터를 공유로 사용 (**공동 접근**)
- . 변경: 추가/삭제/갱신 등의 기존 데이터 변경 가능 (정확한 데이터 유지)

■ 데이터베이스의 다양한 측면에서 특징

- . 정보 축적 및 전달 측면: 성, 성, 성
- . 정보 이용 측면: 다양한 정보를 신속하고 정확하게 경제적으로 이용 가능
- . 측면: 일정한 질서 및 구조에 따라 저장하여 체계적 정보 축적 가능
- . 측면: 정보처리, 검색, 정보전송을 위한 네트워크 기술 등이 발전
- . 경제 산업적 측면: 정보를 신속하게 이용, 제공하여 국민 편의성 증진

■ 데이터 종류

데이터 (Structured)	. 행/열로 구성된 스프레드시트 형태 (관계형 데이터베이스)
데이터 (Semi-structured)	. 데이터 구조에 대한 메타 정보 / Parsing 활용 구조 파악 (Parsing: 반정형 데이터 구조를 해석하여 정보 추출) . HTML, XML, JSON 등 웹 기반 데이터
데이터 (Unstructured)	. 형태 및 구조가 정형화되지 않은 데이터 (사진, 영상, 소리, 텍스트 등)

■ 데이터베이스 구성 요소

- . : 데이터에 대한 데이터 (데이터 특성, 구조, 의미, 관리 정보 설명)
데이터베이스 내 데이터에 대한 정보를 제공하거나 설명
- . : 데이터베이스에서 데이터 검색 및 정렬을 빠르게 수행하기 위한 자료 구조

■ (D)

- 사용자의 요구에 따라 정보를 처리하고 데이터베이스를 관리하는 소프트웨어
- 장점: 데이터의 중복 최소화, 일관성 및 무결성 유지, 모든 사용자 동시 접근 가능
데이터 액세스 권한 제어를 통해 민감 정보 보호, SQL 기반 언어로 제어 용이
타 사용자가 트랜잭션 시에도 결과 즉시 확인 가능
(데이터 상태를 변환시키는 일련의 연산 작업)
- 단점: 모든 데이터 문제 해결 불가, 유지/보수 비용 발생, 전문 지식/관리 필요
시스템 문제 발생 시 모든 데이터에 영향, 새로운 버전 적용 시 호환성 문제

DBMS	. 관계형 데이터베이스 관리 시스템 . 정형화된 테이블로 구성된 데이터 항목들의 집합체 ex. MySQL (오픈소스 DBMS) / Oracle Database (상용 RDBMS) Microsoft SQL Server, IBM DB2, PostgreSQL, Sybase
DBMS	. 객체 지향 데이터베이스 관리 시스템 . 복잡한 데이터 구조를 표현/관리 . 객체를 생성하여 계층에서 체계적으로 정리하고, 상위 계층으로부터 방법과 속성을 다시 물려받음(상속)

- ★ (): 관계형 데이터베이스보다 덜 제한적인 일관성 모델 이용
디자인 단순화, 수평적 확장성, 세세한 통제
ex. MongoDB, Apache HBase, Redis, Apache Cassandra

■ 시대별 데이터베이스 솔루션

1980년대		. O: / 온라인 거래(갱신) 처리 . 주 컴퓨터와 연결된 사용자들의 실시간 트랜잭션 처리
		. O: / 온라인 분석(조회) 처리 . 다차원의 데이터를 대화식으로 분석 및 통계 요약 정보 제공
2000년대		. C: 고객 이해 를 바탕으로 한 마케팅 전략을 통해 높은 이익 창출
		. S: (공급망 관리) . 정보기술을 활용하여 유통 재고 및 시간/비용 최적화

■ 분야별 데이터베이스 솔루션

	. Enterprise Resource Planning . 프로세스 관리를 돕는 여러 모듈로 구성된 통합 애플리케이션
	. 비즈니스 프로세스를 투명하고 민첩하게 유지, 지연시간 제거, 대기업-중소기업 간 협업적 IT화
(B)	. 데이터 웨어하우스 내 데이터에 접근하여 경영 의사 결정에 필요한 정보 획득 및 활용 (데이터 통합 및 분석) . 하나의 특정 비즈니스 질문에 답변하도록 설계 ★ Ad Hoc Report : 특정 요구에 의해 즉각 생성된 보고서
(B)	. 통계적이고 수학적인 분석에 초점 (BI보다 진보된 형태)
	. 지식관리시스템 / 조직 내의 지식을 체계적으로 관리하는 시스템
	. E: 여러 애플리케이션의 비즈니스 정보를 중앙 집중화 → 조직 전체에서 분석/사용 가능하도록 하는 데이터베이스



■ 빅데이터: 대용량 데이터를 활용하여 새로운 통찰 및 가치를 생산

3V: [] (데이터 양 ↑), [] (정형 + 비정형 + 반정형), [] (빠른 속도)

4V: 3V + [] (빅데이터 4번째 V, ROI) ← 비즈니스 효과 관점

Return On Investment, 투자 대비 수익률

사전 처리 → [] 처리 / 표본조사 → [] 조사 / 질 → [] 인과관계 → []

★ 기억 용량 단위

KB (2^{10} , 10^3) → MB (2^{20} , 10^6) → GB (2^{30} , 10^9) → TB (2^{40} , 10^{12})

→ PB (2^{50} , 10^{15}) → EB (2^{60} , 10^{18}) → ZB (2^{70} , 10^{21}) → YB (2^{80} , 10^{24})

★ 자료 구성 단위

- Bit → Nibble (4Bit) → Byte (8Bit) → Word (명령 단위) → Field → Record
→ File → DB

※ [] = 데이터 최소 단위 (이진수 하나)

[] = 숫자, 영어, 공백, 특수문자 (반각문자) / [] = 한글, 한자(전각문자)

■ 빅데이터 출현 배경

- 소셜 미디어(SNS), 영상 등 비정형 데이터 확산, 저장 처리 장치 가격 하락

- [] 컴퓨팅(분산 병렬처리로 처리 비용 감소), 인터넷 보급, 디지털화

- 인간 게놈 프로젝트 / 양질 전환 번칙 / IoT 확산

데이터의 양적 축적이 질적 비약으로 변환

■ 빅데이터에 거는 기대 (비유적 표현)

- 철/석탄(1차 → 2차 산업혁명의 핵심 재료), [] (주요 에너지원)

[] (생물학에서 현미경 렌즈의 중요성), [] (공동 활용 목적의 유/무형 구조물)

■ 빅데이터 가치 산정의 어려움

- 데이터의 활용 방식이 다양해지면서 특정 데이터의 활용 시점/장소/대상 불분명

- 새로운 분석 기술의 적용으로 가치가 없던 데이터가 나중에는 가치 창출될 수 있음

■ 빅데이터 활용 방법

연관 규칙 학습	. 데이터 변수 간 의미있는 상관관계(연관 규칙) 발견 ex. 기저귀 구매와 맥주 구매 간 상관성
유형 분석	. 사용자의 특성(유형)에 맞게 그룹 및 범주를 나누어 분류
유전 알고리즘	. 최적화가 필요한 문제 해결을 자연선택, 돌연변이와 같은 메커니즘을 통해 점진적으로 진화
기계 학습	. 훈련 데이터로부터 패턴을 파악해 예측 (넷플릭스 추천 영상)
회귀 분석	. 선형 함수로 나타낼 수 있는 수치데이터 분석
감정 분석	. 글쓴이의 감정 분석 / 고객이 원하는 것을 찾아낼 때 활용 고객의 후기를 받아 서비스 개선에 활용
소셜 네트워크 분석	. 영향력 있는 사람을 찾아 사람들 간의 소셜 관계를 파악

■ 빅데이터 위기 요인: 사생활 침해 / 책임 원칙 훼손 / 데이터 오용

사생활 침해	. 개인 정보가 n차 가공되어 공유 / <u>익명화 기술로는 해결 불충분</u> → 동의제에서 []로 전환 (개인 정보 사용자에게 책임 부여)
책임 원칙 훼손	. 빅데이터 예측 기반 잠재적 위험 감지 후 책임 추궁 (ex. 실제 범행 전 용의자 사전 체포 / 개인 신용도 무관 대출 거절) → [] <u>강화</u> (결과 기반 책임 원칙)
데이터 오용	. 빅데이터 기반 분석이 항상 맞는 결과를 제공하진 않음 → 데이터 <u>알고리즘 접근권 허용</u> 및 객관적 인증방안 도입 [] [] 도입

★ 개인 정보 비식별화 방법

- 가명 처리 / 총계 처리 (개인 점수 → 그룹 평균) / 데이터 값 부분 및 전체 삭제
/ 데이터 범주화 (27세 → 20대) / 데이터 마스킹 (주민번호 : 980402-2*****)

■ 빅데이터 활용에 필요한 3요소

① [] : 모든 것의 데이터화 (Datafication)

② [] : 데이터 분석 및 처리기술의 진화 / 인공지능 AI 출현

③ [] : 데이터 사이언티스트 및 알고리즘리스트의 중요성 증대

■ 데이터 사이언스

- 정형/반정형/비정형 등 다양한 형태의 데이터에서 의미/가치를 추출

- 총체적(holistic) 접근법 사용 : 수학/통계학/컴퓨터 공학/데이터 공학 등

- 데이터 [] : 분석 보고서 및 시각화 자료 작성 → 데이터 기반 의사 결정 추구

■ 데이터 [] : 머신 러닝 및 AI 활용을 위한 코딩 스킬, 통계적 지식 필요

+ [] 스킬 : Machine Learning + Modeling + Data Technical Skill (이론 지식)

+ [] 스킬 : 창의적 사고, 스토리텔링, 시각화, 커뮤니케이션 (고객 공감 능력)

→ 통찰력 있는 분석 능력

★ 가트너(Gartner)가 주장한 데이터 사이언티스트의 역량

- 데이터 관리, 분석 모델링, 비즈니스 분석, 소프트 스킬 ([] 스킬 제외)

★ 효과적인 분석모델 개발을 위한 요구사항 (인문학적 요소)

- 분석 모델이 예측할 수 없는 위험 요소를 지속적으로 판단

- 모델 능력에 항상 외구심을 가지며, 분석 모델의 한계에 대해 끊임없이 고찰

- 모델 범위 바깥의 외부 요인은 판단하지 않음 (가정과 현실의 불일치)

▶ 과학 기반의 정량 분석 + 인문학적 통찰 기반 합리적 추론

(과거: 모델링, 실험설계 / 현재: 차선 행동 / 미래: 예측, 최적화)

→ '인과관계'가 아닌 '상관관계' 분석 기반 인사이트 중요도 높아짐

▶ 사회경제적 변화: 단순 세계 → 복잡 세계 (다양성, 연결성, 창조성)

(인문학 열풍) 비즈니스 중심의 제품 생산 → 서비스 중심

경제 및 산업 논리의 생산 → 시장 창조 (무형 자산)

■ 가치 패러다임의 변화: D [] (디지털 정보 간 연결) → C [] → A []

(아날로그 → 디지털)

(효율/효과적인 연결 지향)

- 일차적 분석: 큰 변화에 대응하거나 고객 환경의 변화 파악, 새로운 기회 포착이 어려움

- 전략도출 가치기반 분석: 전략적 통찰력 창출을 통해 기회 발굴

주요 경영진의 지원 확보 / 넓은 활용 범위 / 전략적인 변화

■ 데이터 웨어하우스

데이터 웨어하우스 (Data Warehouse)	. 기업 내 의사결정 지원을 위한 하나의 통합된 데이터 저장 공간 [4대 특징] ① [] : 전사적 차원에서 일관된 형식으로 정의 ② [] : 시간의 흐름에 따라 변화값 저장 ③ [] : 특정 주제에 따라 분류/저장/관리 ④ [] : Batch 작업에 의한 갱신 이외에 변화 X
데이터 마트 (Data Mart)	. 소규모 단일 주제의 데이터 웨어하우스 → 전사적 데이터에서 특정 부서·업무·주제를 중심으로 추출 → 데이터 [] 입장에서 분류된 소규모 데이터 웨어하우스



- **분석 프로젝트** : 비즈니스 영역과 데이터 영역의 현황 파악 / 구성원과 협업 중요
애자일(Agile) 프로젝트 관리 방식 / 분석 과제 정의서 기반 프로젝트 수행

★ **분석 과제 정의서**

- 분석에 필요한 소스 데이터, 분석 방법, 데이터 입수 및 분석 난이도, 분석 수행주기, 분석 결과에 대한 검증 등을 정의
- 이해관계자들의 프로젝트 방향 설정 및 성공 여부 판단의 명확한 기준 작성

■ **분석 과제 주요 특징 5가지**

- 데이터 / 데이터 / / 분석 /
Data size Data Complexity Speed Analytic Complexity Accuracy & Precision

- * (): 높을수록 모델과 실제 값 사이의 차이가 적음
- * (): 높을수록 모델을 지속 반복했을 때의 결과 편차가 적음
→ ‘정확도’와 ‘정밀도’ 간에 Trade-off 관계 존재 (정확도 ↔ 복잡도 마찬가지로)
→ 분석의 활용 측면에서는 중요, 안정성 측면에선 중요

■ **분석 프로젝트 관리 방안 10가지**

- 시간 / 범위 / 품질 / 통합 / 이해관계자 / 자원 / 원가 / 리스크 / 조달 / 의사소통

	타임박스 (Time Boxing) 기법을 사용하여 분석 결과 도출까지의 병목 현상을 관리하고, 주요 마일스톤별 일정을 계획대로 준수함
	분석의 목적에 맞는 데이터 범위와 분석 모델의 경계를 명확하게 설정하여 프로젝트의 확산을 방지함
	분석 모델의 정확도와 신뢰성을 확보하기 위해 지속적인 품질 검증과 성능 모니터링을 수행함 . 품질 : 품질 정책 수립, 데이터 품질 목표 및 관리 프로세스 정의 . 품질 : 계획된 품질 기준으로 실제 산출물의 품질 확인/점검 . 품질 : 신뢰성 확보를 위한 분석 프로세스 지속적인 개선/보완
	프로젝트 내 다양한 활동과 분석 프로세스를 유기적으로 결합하고 조정하여 일관된 방향성을 유지함
	데이터 제공자, 현업 부서, 의사결정자 등 이해관계자의 요구사항을 파악하고 원활한 협의를 도출함
	분석을 수행할 전문 인력과 서버, 소프트웨어 등 인적 및 물적 자원을 정해진 예산 범위 내에서 효율적으로 배정함
	데이터 확보 및 인프라 구축 등에 소요되는 예산을 산정하고, 제한된 자원 내에서 비용 효율을 극대화함
	데이터 부족, 모델 성능 미달 등 발생 가능한 위험 요소를 사전에 식별하고 대응 방안을 마련하며 프로젝트 종료까지 지속적인 모니터링 필요
	외부 데이터 구매나 분석 톨 도입 등 외부 자원이 필요한 경우 적절한 계약(외부 소싱)과 공급업체 관리를 수행함
	분석의 진행 상황과 중간 결과를 프로젝트 이해관계자 간에 투명하게 공유하여 조직 내 공감대를 형성하고 신뢰를 확보함

- ★ 전략적 / / (비즈니스 성과)

■ **분석 마스터 플랜**

- 데이터 분석 과제 도출 → 과제 우선순위 결정 → 적용 우선순위 결정
→ 분석 구현 로드맵 수립 (적용 범위/방식 고려)
업무 내재화 / 분석 데이터 / 기술 적용 수준
- * 모델링 단계만 반복적으로 수행하는 혼합형이 주로 적용

※ 과제 우선순위 평가기준 - 전략적 중요도


	목적 및 업무에 밀접하고 직접적인 연관이 있고, 문제 발생 시 위험 손실 정도가 있는 경우
	요구사항 만족, 효율 향상, 경쟁우위 확보 등을 위한 정도

- (if / 정보 전략 계획)

- 전략적 주요 정보를 대상으로 전사적인 종합추진 계획 / 중장기 마스터 플랜 수립

★ **분석 우선순위 평가 기준**

- . 시급성 : 전략적 / 목표 가치 → 비즈니스 효과 (Return) :
- . 난이도 : 데이터 획득, 저장, 가공 비용 / 분석 적용 비용 / 분석 수준
→ 투자비용 요소 (Investment) : Volume, Variety, Velocity



- ★ : 과제 계획서로 목표 달성을 위한 방향 및 일정을 시각적으로 표현한 문서

■ **분석 거버넌스 체계** : 의사결정을 위한 데이터 분석과 활용을 위한 관리체계

- 구성 요소 : 프로세스 (Process) / 조직 (Organization) / 시스템 (System)
인적 자원 (Human resource) / 데이터 (Data)
분석 관련 교육 / 마인드 육성 체계 데이터 거버넌스

■ **데이터 분석 조직 구조**

조직	. 별도 독립적 분석 조직 구성 (조직 내 분석 업무 일괄 담당) → 전사 차원에서 전략적 중요도에 따라 우선순위 결정 → 협업 부서와 중복 업무 가능성
조직	. 별도 독립 조직 없이 각 해당 부서에서 직접 분석 → 전사적 관점 분석 관리 어려움
조직	. 독립적 분석 조직의 인력을 협업부서에 배치시켜 업무 수행 → 분석 결과의 신속한 실무적용 가능

■ **빅데이터 플랫폼**

- 수집한 데이터를 저장·처리하고 분석할 수 있도록 포괄적으로 지원하는 통합 환경
- 데이터 → 저장 → 데이터 → 데이터 → 시각화의 전 과정 지원
ETL, 크롤링, API MapReduce, Spark R, Python, ML/AI 도구

- ★ 계층 구조 : (하위) ▶ (중간) ▶ (상위)

	분석·시각화·BI 도구 등 사용자 직접 사용 SW
	데이터 및 자원 할당 관리, 빅데이터 어플리케이션 실행을 위한 서비스 제공
	물리 자원, 클러스터 노드 관리 / 기반 기술·환경 Ex. 서버, 스토리지, 네트워크, 노드 자원관리(YARN)

★ **빅데이터 분석 플랫폼 구분**

광의의 분석 플랫폼	분석 서비스 제공 엔진 / 분석 어플리케이션 / 분석 서비스 API / 하드웨어 및 운영체제(OS)
협의의 분석 플랫폼	데이터 처리 / 분석 / 분석

■ **분석 과제 관리 프로세스**

- . 과제 발굴 : 분석 아이디어 발굴 / 과제 후보 제안 / 분석 과제 확정
- . 과제 수행 : 팀 구성 / 분석 과제 실행 / 분석 과제 진행 관리 / 결과 공유 및 개선
→ 분석 과제 진행 중 시사점과 분석 결과물들은 풀(Pool)에 축적하여 관리



■ 데이터 분석 수준 진단

1. 데이터 분석 (Readiness)


분석	사실 분석 / 예측 / 시뮬레이션 / 최적화 / 분석 업무 정기적 개선
인력 및	분석 전문가 / 관리자 분석 능력 / 분석 업무 조직 / 경영진 이해
분석	적절한 분석 기법 / 분석 기법 라이브러리, 평가, 정기적 개선
분석	데이터 관리 / 외부 데이터 활용 / 기준데이터 관리 (MDM)
분석	사실 기반 의사결정 / 회의에서 데이터 활용 / 데이터 공유 및 협업 / 관리자의 데이터 중요성 인지
	운영 시스템 데이터 통합 / 분석 환경

2. 데이터 분석 (Maturity)

- CMMI 모델 기반 비즈니스, 조직 및 역량, IT 부문 관점으로 구분 (비용 고려 X)

	. 환경, 시스템 구축 / 데이터 웨어하우스, 데이터 마트, ETL, OLAP . 실적 분석 및 통계 작성
	. 분석 결과 업무에 적용 / 실시간 대시보드, 통계분석 환경
	. 전사 차원 분석 관리 및 공유 / 비주얼 분석, 분석 전용 서버
	. 혁신 및 성과 향상에 기여 / 분석 Sandbox, 프로세스 내재화, 빅데이터

■ 데이터 분석 성숙도 모델



	데이터, 조직, 분석업무, 분석기법 등 미적용되어 사전 준비 필요
	데이터, 조직, 분석업무, 분석기법 등을 내부에서 제한적으로 사용
	분석업무 및 기법이 부족하나 조직 및 인력 등 준비도는 높은 상황
	6가지 분석 구성요소 갖춘 상태 / 지속적 확산 가능

▶ 분석 지원 인프라 방안 수립 : 확장성을 고려한 플랫폼 시스템 적용 (중앙집중적)

■ 데이터 거버넌스 : 전사 차원의 데이터 관리 체계 구축

- 구성 요소 : / /

- 관리 대상 : 마스터 데이터, 메타데이터, 데이터 사전

. 데이터 거버넌스 체계 요소


데이터 표준화	데이터 표준용어 설정, 명명 규칙 수립, 메타데이터 및 데이터 사전 구축
데이터 관리체계	효율적 데이터 관리를 위한 관리 원칙 수립
데이터 저장소관리	전사 차원의 저장소 구성
표준화 활동	거버넌스 체계 구축 후 표준 준수 여부를 주기적 점검

■ 빅데이터 거버넌스

- 기존 데이터 거버넌스 체계에 빅데이터의 효율적 관리, 다양한 데이터 관리 체계, 데이터 최적화, 정보 보호, 데이터 카테고리별 관리 책임자 지정 등을 포함



■ 상자그림 (Boxplot) 해석



■ 결측값 (Missing Value)

- 데이터 값이 없는 데이터 (null or NA), 관측되지 않는 특정 확률변수의 값
- 반드시 제거하는게 아니라 상황에 따라 제거 여부 판단

☐ (단순 삭제)	결측값을 가진 불완전 데이터 제거 (Complete case analysis) → 효율성 상실 및 통계적 추론의 타당성 문제 존재
☐	. 비조건부 : 데이터의 평균으로 결측값을 대체 . 조건부 : 회귀분석 활용
☐	평균 대체법의 추정량 표준오차의 과소 추정 문제 보완 목적으로 결측값을 대체할 때 적절한 확률값을 부여한 후 대체 → Hot-deck / K-Nearest Neighbor (KNN) 모델 활용
☐	단순 대체법을 여러번(m번) 시행 (대치→분석→결합)

■ 이상값 (Outlier)

- 극단적으로 크거나 작은 값 (정형 데이터보다 반정형/비정형 데이터에서 주로 발생)
- 반드시 제거해야 하는 것은 아님 → 분석 목적/종류에 따라 전문가의 판단 필요

☐	. 평균으로부터 표준편차의 3배(3σ)를 벗어나는 데이터 $\mu - 3\sigma < \text{정상 데이터} < \mu + 3\sigma$
사분위수	. Q1 및 Q3에서 각각 IQR의 ☐ 배 벗어나는 데이터 (Q1 - ☐ x IQR) < 정상 데이터 < (Q3 + ☐ x IQR)

■ 확률적 표본추출법

☐ 추출	무작위로 표본 추출 (표본 선택 확률 모두 동일)
☐ 추출	일련번호 (1, 2, ..., n) 부여 후 일정 간격으로 표본 선택
☐ 추출	모집단을 서로 중복되지 않는 집단 및 층(strata)으로 구분하고 각 집단 내에서 표본을 무작위 추출 (ex. 성별, 나이, 지역) → 집단 간 ☐ 성, 집단 내 ☐ 성
☐ 추출	모집단을 서로 동질적인 집단으로 나누고, 몇 개의 집단들을 선택 후 해당 집단 내에서 표본을 임의로 선택 (ex. 같은 학년 내 반) → 집단 간 ☐ 성, 집단 내 ☐ 성

※ 표본추출 관련 오차

- . **표본 오차** : 표본의 낮은 대표성으로 표본으로 선택되지 않은 데이터들로 인한 오차
→ 표본의 크기가 커질수록, 즉 전체 데이터를 대변할수록, **표본 오차는 0으로 수렴**
- . **비표본 추출 오차** : 표본 오차 이외의 발생가능한 모든 오차
→ 데이터 수집, 조사, 분석 과정 (**표본 크기 커질수록 비표본 추출 오차도 커짐**)
- cf. 표본 ☐ (Sampling ☐) : 일부 데이터만의 특성이 극단적으로 반영된 표본
→ 확률화(Randomization) 과정을 통해 최소화 또는 제거 가능

■ 요약변수 / 파생변수

☐ 변수	공동으로 사용 가능 / 많은 모델에서 사용하여 재활용성이 높음 ex. 기간별 총 구매금액, 구매 횟수
☐ 변수	사용자가 의미를 부여한 변수 / 매우 주관적이라 논리적 타당성 필요 ex. 기간 별 구매지수, 선호지수

■ 자료의 척도


☐ 척도	측정 대상의 특성을 분류 (ex. 성별 / 지역 / 학교), 순위(서열) 없음
☐ 척도	높고 낮음의 서열관계가 존재 할 뿐 양적 비교는 불가 (ex. 학년, 점수, 만족도)
☐ 척도	부여된 순위 간 간격이 동일 / 양적 비교 가능 (덧셈, 뺄셈) (ex. 온도, 물가지수, IQ → 절대적 기준 0이 존재 불가)
비율척도	절대적 기준 0이 존재하며 비율 계산 가능 (사칙연산) (ex. 무게, 나이, 거리)

■ 기초 통계 용어

평균 (Mean)	. 데이터의 전체 합을 개수로 나눈 값 $\mu = (x_1 + x_2 + x_3 + \dots + x_n) / n$
☐ (☐)	. 데이터를 크기 순으로 나열했을 때 중앙에 위치하는 값 → 짝수 개일 때, 중앙 2개의 값의 평균을 중앙값으로 계산
☐ (☐)	. 가장 많이 나오는 값 (1개 이상일 수 있음)
(모)분산	. 데이터가 퍼져있는 정도 (σ^2 , 편차 제곱의 평균) = $\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$
표준편차	. 분산의 제곱근 값 = $\sqrt{\sigma^2} = \sigma$
표본분산	. 모분산 계산식에서 n 대신 n-1을 나눔 = $\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$
☐ (☐)	. 표본 집단의 평균값과 모집단의 평균값 간의 차이 . 표준오차 = $\frac{\sigma}{\sqrt{n}}$ → 데이터 수(n)가 클수록 표준오차는 작아짐
☐ (☐)	. 두 개의 확률변수의 선형 상관관계 정도 (최대/최소 없음) → 0 : 상관관계 없음 / > 0 : 양의 상관관계 / < 0 : 음의 상관관계 . 두 확률변수 X, Y가 ☐ 이면 공분산 COV(X, Y)는 ☐ (역은 성립 X) ▶ $\text{COV}(X, Y) = E[(X - E[X])(Y - E[Y])]$
☐	. 두 변수 사이의 특정 상관관계 지수 . -1 ~ 1 사이의 값 존재 (1 : 정비례 / -1 : 반비례) ※ 높은 상관계수가 높은 인과관계를 대변하진 않음
Z-score	. 데이터의 평균으로부터 떨어진 정도를 나타내는 척도 (표준화) ▶ $Z = \frac{x - \mu}{\sigma}$ (μ : 평균 / σ : 표준편차)


※ **근원사건** : 표본 공간 내에 원소가 한 개만 존재하는 사건 (표본의 최소 단위)

■ 첨도 : 자료 분포가 얼마나 뾰족하거나 완만한지 나타내는 정도 (중앙에 몰린 정도)



■ 왜도 : 자료 분포의 비대칭 정도 (0 : 좌우 대칭관계)

★ 평균값은 꼬리의 방향에 따라감





■ 확률 기본 용어

조건부 확률	특정 사건 B가 발생했을 때 A가 발생할 확률 ▶ $P(A B) = \frac{P(A \cap B)}{P(B)}$
종속 사건	두 사건 A, B가 서로에게 영향을 주는 사건 ▶ $P(A \cap B) = P(A) \cdot P(B)$
독립 사건	두 사건 A, B가 서로 영향을 주지 않음 ex. 100원 동전이 앞이 나올 확률(A)과 500원 동전이 앞이 나올 확률(B) ▶ $P(A B) = P(A)$, $P(B A) = P(B)$ → $P(A \cap B) = P(A) \cdot P(B)$
배반 사건	두 사건 A, B가 동시에 일어나지 않는 사건 → $P(A \cap B) = \emptyset$ (공집합) ex. 동전을 던졌을 때 앞면과 뒷면이 같이 나올 확률

※ $P(A|B)$ 정리: $P(A|B) = \frac{P(A \cap B)}{P(B)}$

$P(A|B)$ - 사후 확률 (Posterior): 사건 B 발생 후 갱신된 사건 A 확률
 $P(A)$ - 사전 확률 (Prior): 사건 B 발생 이전의 사건 A 확률
 $P(B|A)$ - 가능도 (Likelihood): 사건 A 발생 시 사건 B의 확률
 $P(B)$ - 정규화 상수 (Normalizing constant), 증거 (Evidence): 확률의 크기 조정

■ 확률 분포

이산 확률분포	이항분포	정의된 모든 곳에서 확률분포 값이 일정 확률변수가 n개일 때, 모든 시행의 확률은 1/n로 동일
	다항분포	각 시행마다 오직 두 가지의 결과만 존재 ▶ 기댓값: $E(x) = np$, 분산: $V(x) = np(1-p)$
	이항분포	독립적인 베르누이 시행을 n회 반복할 때 성공한 횟수(x)의 확률분포 ▶ 기댓값: $E(x) = np$, 분산: $V(x) = np(1-p)$
	기댓값 $E(x)$ = $\frac{1}{p}$	처음 성공까지 시도 횟수(x)를 확률변수로 가짐 ▶ 기댓값: $E(x) = 1/p$, 분산: $V(x) = (1-p)/p^2$
	포아송분포	단위 시간/공간에서 사건의 발생 횟수 ▶ 기댓값: $E(x) = \lambda$, 분산: $V(x) = \lambda$
연속 확률분포	정규분포	$N(\mu, \sigma^2)$ / 가우스분포 → Z검정 ※ 평균 0, 분산 1인 정규 분포 → 표준 정규분포: $N(0,1)$
	이항분포	정규분포에서 표본이 적은 경우 ($n < 30$) 사용 → T검정 ※ 표본 개수가 30개 이상이면 정규성 검정 불필요 → 두 집단의 평균을 비교할 때 사용
	단일 모집단의 모분산에 대한 가설 검정	→ 0 이상의 값만 존재 / 오른쪽 꼬리가 긴 형태
	두 집단의 분산의 동일성 검정	
	연속균등분포	연속확률분포로 분포가 특정 범위 내에서 균등함
연속 확률분포	이항분포	서로 독립적인 사건에서 다음 사건이 일어날 때까지의 경과 시간에 대한 연속확률분포

■ 확률질량함수 vs 확률밀도함수

확률질량함수 (PMF)	확률밀도함수 (PDF)
이항변수 (주사위 눈, 동전 던진 횟수 등)	연속변수 (키, 몸무게, 시간 등)
함수값 자체가 해당 값의 확률을 나타냄 (0과 1 사이의 값)	함수값은 확률의 진하기(밀도)를 나타냄 (0 이상의 값, 1보다 클 수 있음)
$\sum P(X=x) = 1$	$\int f(x)dx = 1$
주사위 눈이 x일 확률	몸무게가 a에서 b 사이일 확률

■ 추정 방법

점 추정	모집단에서 표본을 추출하여 모집단의 모수를 추측하는 과정에서 범위가 아니라 가장 참값이라고 여겨지는 하나의 모수를 선택 (적률법, 최대가능도추정법/최대우도법, 최소제곱법)
구간 추정	모수를 포함할 것으로 기대되는 구간을 확률적으로 계산
모수적 추론	모집단에 특정 분포를 가정하고(가설검정) 모수에 대해 추론 필수 요소: 정규분포 + 등간척도 or 비율척도 → 모수의 평균, 분산 (분포의 형태)
비모수적 추론	모집단에 대한 정보가 없어 특정 분포를 따른다는 가정 불가 정규분포가 아니거나, 표본 수가 적을 때 ($n < 30$) → 중앙값, 순위 ex. 부호검정 (Sign test) 윌콕슨 순위합 검정 (Wilcoxon rank-sum test) 윌콕슨 부호 순위 검정 (Wilcoxon signed-rank test) 스피어만 순위상관계수 (Spearman's rank correlation) 맨-휘트니 U 검정 (Mann-Whitney U test) 콜모고로프-스미르노프 검정 (Kolmogorov-Smirnov test) 크루스칼-왈리스 검정 (Kruskal-Wallis H test)




■ 가설 검정: 모집단에 대한 어떤 가설을 세우고, 표본조사로 그 가설의 채택여부 판정

H_0	가설검정의 대상이 되는 가설 / 일반적으로 알려진 가설 → 내 친구 영호는 범인이 아니다!
H_1	내가 증명하고자 하는 가설 / 귀무가설을 기각할 수 있는 가설 → 무슨 소리! 영호가 범인이야!
α	귀무가설이 참일 때 기각할 가능성(제 1종 오류)의 최대 허용 한계 → 영호가 범인이 아닌데, 영호를 범인이라고 생각할 확률 ※ $\alpha = 0.05$ (5%): 100번 테스트 중 1종 오류는 최대 5번까지만 허용
$(1-\alpha)$	제 1종 오류를 범하지 않을 확률 → $\alpha = 0.05$ 이면, 신뢰수준은 0.95(95%)이다.
(p-value)	귀무가설이 맞을 확률 = 대립가설이 틀릴 확률 → p-value < $\alpha(0.05)$: 대립가설이 틀릴 확률(p-value)이 1종 오류 최대 허용 한계인 5%보다 낮아서 95% 신뢰수준으로 대립가설 채택! = 최종 영호는 범인이다! (H_0 기각)




실제 사실	내가 선택한 결정	
	H_0 채택 (범인은 영호가 아냐)	H_0 기각 (아냐, 영호가 범인이야!)
H_0 = 참 (영호 범인X)	올바른 결정 (신뢰수준 = $1-\alpha$)	오류 (α) 결백한 영호를 범인으로 오해
H_0 = 거짓 (영호 범인O)	오류 (β) 범인인 영호를 용의자에서 제외	올바른 결정 (검정력 = $1-\beta$)

[양측 검정]



H_0 : 수학 점수 평균은 80점이다
 H_1 : 수학 점수 평균은 80점이 아니다

[단측 검정]




H_0 : 수학 점수 평균은 80점 이상이다.
 H_1 : 수학 점수 평균은 80점 미만이다.

※ 정규성 가정 미충족 시, Box-Cox, log, exp 등의 함수 적용하여 정규성 부여 가능



※ 표본의 크기와 신뢰구간의 관계



· 표본 크기(n)가 클수록, 신뢰수준 임계값(z)과 모표준편차(σ)가 작을수록

신뢰구간의 길이는 []

→ 신뢰구간이 좁혀짐에 따라 추정의 정밀도 []

※ 바람직한 추정량 판단 기준

[]	표본의 크기가 커지면 표본오차가 작아져야 함
[]	추정량의 기댓값이 모수의 값과 동일
[]	최소 분산 추정량 (추정량의 분산은 최대한 작아야 함)

※ 중심극한정리

- 확률변수 X 의 모집단 분포가 정규분포가 아니더라도 표본 크기가 충분히 크다면 랜덤한 표본 평균의 분포는 근사적으로 []를 따름
 → 표본 크기가 크다면 표본의 통계량을 이용해 모집단의 모수/특성 추정 가능

※ 상관계수의 선형 변환에 따른 불변성

- 변수 X 와 Y 에 일정한 숫자를 더하거나 곱해도 기존 상관계수 값은 []
 (단, []를 곱하는 경우만 상관계수의 부호가 반대로 바뀐)

$$\rho(aX + b, cY + d) = \frac{ac}{|ac|} \rho(X, Y)$$

[예시] 변수 X 와 Y 의 상관계수가 0.5일때, $(2X + 0.2)$ 와 $(3Y + 0.3)$ 의 상관계수는 []
 단, $-2X$ 와 Y 의 상관계수는 [] (부호 역전 발생)

■ 범주형 자료 분석

- 범주형 자료: 관측된 결과를 어떤 속성에 따라 분류 후 도수로 주어진 데이터 (교차표)
 → 일반적으로 [] 검정 추론 [참고] t-test는 연속형 변수에 적용

[] 분석	1개의 범주형 변수에 대해 데이터가 특정 분포를 만족하는지 검정 → 피어슨 카이제곱 검정 ex. 주사위 1이 나올 확률 검증 / 멘델의 유전 법칙 유효성 검증
[] 분석	서로 다른 집단에 대한 두 범주형 변수가 서로 다른 요인에 영향을 주는지 검정 Ex. 지지하는 정당과 살고 있는 지역 간의 상관관계
[] 분석	서로 다른 모집단에서 관측된 값들이 범주 내에서 동일한 비율로 나타나는지 검정 ex. 남녀 간 선호 지역 / 학년별 학과 만족도

※ 교차 분석: 2개 이상의 []형 변수(성별, 혈액형) 간의 빈도와 비율을 분석
 → 관측 빈도와 기대 빈도의 차이를 측정하는 [] 통계량 사용
 → 데이터의 정규성 가정이 불필요한 비모수 검정 분석 방법

■ 회귀분석: 하나 이상의 독립변수들이 종속변수에 미치는 영향을 추정하는 통계 분석

- [] 변수: 입력 값, 원인 $\rightarrow x$ 값
- [] 변수: 출력 값, 결과 $\rightarrow y$ 값 $y = f(x)$
- [] (오차): 계산을 통한 이론값과 실제 측정값 간의 차이
모집단을 기준 $\rightarrow$ 오차(Error) / 표본집단을 기준 $\rightarrow$ 잔차(Residual)

※ 명목형 변수는 더미변수화하여 사용 가능

■ 회귀분석 시 가정

[]	독립변수와 종속변수 간에는 선형 관계가 있음
[]	독립변수와 오차(잔차) 간에는 서로 관련이 없음
[]	오차(잔차)의 분포가 정규분포를 따름 → Q-Q plot, 히스토그램, 왜도/첨도, Kolmogorov-Smirnov Test, Shapiro-Wilk test, Anderson-Darling Test로 정규성 확인 가능 [주의] 더빈-왓슨 검정 (Durbin-Watson test): 오차항의 독립 여부 (정규성X)
[]	모든 독립변수에 대해 오차(잔차)의 분포는 동일한 분산을 가짐
[]	오차(잔차)끼리는 서로 상관성이 없음

※ 선형성을 제외한 나머지 특징들은 모두 []와 관련 있음

■ 최소제곱법 (최소자승법): []이 가장 작은 선형 그래프 (단순 회귀 분석)

· R-squared (R^2): 단순회귀분석에서 결정계수 (0 ~ 1)

※ []: 추정된 선형 모형이 주어진 데이터에 적합한 정도를 재는 척도
 1에 가까울수록 좋은 모델 (선형성이 강한 모델)

■ 회귀분석 종류 → 종속변수가 연속형일 때, 회귀분석 적합

단순회귀	1개의 독립변수와 종속변수의 선형관계
다중회귀	2개 이상의 독립변수와 종속변수의 선형관계
다항회귀	1개 이상의 독립변수와 종속변수가 2차 함수 이상의 관계
[] 회귀 ([])	L1 규제를 포함하는 선형회귀 모형 (회귀계수 절대값이 클수록 높은 페널티를 부여하여 최소화 유도)
[] 회귀 ([])	L2 규제를 포함하는 회귀 모형 (회귀계수 제곱값이 클수록 높은 페널티 부여)
[] ([])	L1, L2 규제 모두 사용

※ 규제: 선형 회귀 모델의 과적합 문제를 해결하기 위해 가중치(회귀계수)에 페널티 값을 적용하여 가중치가 커지는 것을 방지

→ 회귀계수를 0으로 만들어 변수 제거를 통해 [] 문제 완화 가능



회귀분석 분산분석표 (ANOVA)

요인	제곱합	자유도 (d_f)	제곱평균	F
회귀		(회귀계수 개수)	$MSR = \frac{\text{회귀제곱합}}{\text{회귀자유도}} = \frac{\text{회귀제곱합}}{\text{회귀자유도}}$	$F = \frac{\text{회귀제곱평균}}{\text{잔차제곱평균}} = \frac{MSR}{MSE}$
잔차			$MSE = \frac{\text{잔차제곱합}}{\text{잔차자유도}} = \frac{\text{잔차제곱합}}{\text{잔차자유도}}$	
총	$= SSR + SSE$			



결정계수(R^2)

$$R^2 = \frac{\text{회귀제곱합 (SSR)}}{\text{총제곱합 (SST)}} = \frac{\text{회귀제곱합 (SSR)}}{\text{회귀제곱합 (SSR)} + \text{오차제곱합 (SSE)}} = 1 - \frac{\text{오차제곱합 (SSE)}}{\text{총제곱합 (SST)}}$$

전체 변동 중에서 회귀모형이 설명하는 비율 / 1에 가까울수록, 즉 서로 같을수록 좋은 모델!

SST (Sum of Squares Total) : 총제곱합

SSE (Sum of Squares Error) : 오차제곱합

SSR (Sum of Squares Regression) : 회귀제곱합

$$SST = SSR + SSE$$

▶ $R^2 = 1 - (n-1) \times \frac{MSE}{SST}$ → 다중회귀에서 사용

▶ 전체 데이터 수 (n) = 회귀계수 개수 + 1 > 회귀계수 개수 = n - 1



회귀 모형 해석 및 검증

- 독립변수 및 종속변수 확인
 - 모형이 통계적으로 유의미한가? → $p\text{-value} < 0.05$ 여부 확인!
 - 회귀계수들이 유의미한가? → 각 $p\text{-value} < 0.05$ 여부 확인!
 - 모형이 얼마나 설명력을 갖는가? → R^2 값의 수치 확인 (1에 근접할수록 좋음)
- ※ 다중회귀에서 자유도(d_f)는 회귀계수 개수 사용 (이때, k는 회귀계수의 개수)

▶ 12 page, 'Summary 함수 해석' 관련 예시 자료 참고

최적 회귀방정식 탐색 방법


회귀법	기본 모형에 설명력이 좋은 변수를 하나씩 추가
제거법	모든 변수가 포함된 모형에서 설명력이 낮은 변수를 하나씩 제거
진진선택법	전진선택법에 후진제거법을 추가 . AIC: 편향과 분산이 최소화되는 지점 탐색 → 자료가 많을 때 부정확 . BIC: 기본 AIC 보완 방법 → 변수가 적은 모델에 적합



적합 (일반화)	단순한 모델 / 불충분한 훈련 데이터 학습량 → *일반화 능력 부족 / 새로운 데이터에 대한 예측력 부족
적합 (과대)	과도한 훈련 데이터 학습량 → 잡음(Noise)까지 학습하여 실제 테스트 시 낮은 성능 발현 가능 → 독립변수 개수 줄이기 / 정규화(Regularization) 수행

* R^2 : 한 군집 내의 다른 데이터를 분석해도 동일한 결과 산출되는 특성

Bias	과도하게 단순한 모델 → 높은 편향 시 과소적합 유발
Variance	과도하게 복잡한 모델 → 높은 분산 시 과대적합 유발



상관분석의 유형

양적척도(등간/비율척도) / 연속형 변수 / 두 변수 간의 선형관계 측정
서열척도 / 순서형 / 연속형 / 이산형 변수 → 원시 데이터가 아닌 각 변수에 대해 순위를 매긴 값을 기반 비선형 관계 측정 가능 / 선형 여부 상관없이 단조적 관계 여부 확인



회귀분석에서 독립변수 간에 강한 상관관계가 나타나는 문제

- 일부 설명 변수가 다른 설명 변수와 높은 상관관계로 데이터 분석에 부정적 영향을 줌 (ex. 독립변수: ① 혈중 알코올 농도 / ② 일평균 음주량 → 종속변수: 학업 성적)
- 표본의 크기가 적으면 독립변수 간 상관관계 파악이 어려워 다중공선성 발생가능 높음
- 독립변수 간 상관관계 측정 지표
- 상관관계를 갖는 설명변수를 모형에서 제거하여 해결 가능 (ex. 다차원 척도법 / 주성분 분석)

척도법 (MDS: Scaling)

- 데이터(개체)들 간의 유사성/근접성을 시각화하는 통계 방법
- 다차원의 데이터를 저차원(2 or 3차원) 공간상에 점으로 표현하는 방법
- 개체 간의 거리 표현 (유클리드 거리 / 유사도)
- 스트레스(Stress): 개체 간 적합 정도 수치화 → 0에 가까울수록 높은 적합도
- 계량적 MDS: 양적척도 (구간/비율척도)인 경우
- 비계량적 MDS: 순서척도인 경우




주성분 분석 (PCA)

- 상관관계가 높은 변수들의 선형결합을 통해 차원을 축소하여 변수를 축약 (차원 축소)
- 분산을 극대화하는(=설명력이 높은) 축을 주성분으로 하여 변수를 축약
- 첫 번째 주성분: 전체 변동을 가장 많이 설명하는 축 (가장 큰 분산)
- 두 번째 주성분: 첫 번째 주성분과 낮은 상관성으로 나머지 변동을 가장 많이 설명 가능


[주성분 선택법]

- R^2 (Eigenvalue)이 70~90% 사이의 주성분의 수로 결정 가능
→ 전체변이 공헌도
- R^2 (Eigenvalue)이 1보다 큰 주성분만 사용 또는 평균고유값 이상의 주성분
- R^2 활용해 고유값이 수평을 유지하기 직전의 주성분의 수 결정
→ 그래프의 기울기가 완만해지는 지점



※ 바이플롯 (Biplot)

- 첫 번째 주성분 (x축) / 두 번째 주성분 (y축)을 하나의 2차원 그래프로 표현
- 각 주성분 축과 평행할수록 해당 주성분과 영향력이 높음
- 화살표의 길이가 길수록 분산이 큼



- A와 B는 서로 가까워 높은 상관관계
- 데이터 1은 A에 가장 큰 영향을 받음
- PC1(가로축)과의 영향력 비교: B > A > C
- PC2(세로축)와의 영향력 비교: C > A > B



[예시 - 주성분 분석]

주성분 총 4개

	PC1	PC2	PC3	PC4
Standard deviation	1.5749	0.9949	0.5714	0.4156
Proportion of Variance	0.6201	0.2474	0.0891	0.0433
Cumulative Proportion	0.6201	0.8675	0.9566	1.0000

- . 80% 이상 설명 필요 시 주성분은 최소 개가 필요 (PC2 : 86.75%)
- . 90% 이상 설명 필요 시 주성분은 최소 개가 필요 (PC3 : 95.66%)

- 시계열 분석 : 시간의 흐름에 따라 관측한 데이터로 미래 데이터 분석 (물가, 기온)
→ 시계열 예측을 위해서 '' 을 만족해야 함

※ ()

- 시계열의 평균과 분산이 모든 시점에서 일정하고 특정한 추세가 존재하지 않는 성질
- 분석 시점과 무관하게 과거/현재/미래 모두 안정적이며 일정한 분포를 가짐
- 공분산은 시점에 의존하지 않고, 시차(Lag)에만 의존

[정상시계열 변환 방법]

- : 현 시점의 자료에서 이전 시점의 자료 값을 빼 줌
= t 시점과 t-1 시점의 값 차이 ($\Delta y_t = y_t - y_{t-1}$)
- 변환 : 데이터의 로그함수 취하여 데이터 변동을 조절
- ※ 평균이 일정하지 않으면 차분을, 분산이 일정하지 않으면 변환을 사용
- 기타 방법 : 이상치 제거, 구간분할

■ 시계열 모형

모형	. Model (정상시계열) . (p) : p 시점 이전의 자료가 현재 자료에 영향을 주는 모형 → '자기 자신의 과거 값' + '백색 잡음의 현재 값' 으로 구성 ※ : 시계열 모형의 오차항 의미 / 정규분포 시 가우시안 백색잡음 평균 0이고 분산 일정하며, 시점 간 자기상관성 없는 대표적 정상시계열 → 함수() 통해 p+1차항부터 절단 가능
모형	. Model (정상시계열) . (q) : q 시점 이전 오차들에서 현재항의 상태 추론 → 유한개의 백색잡음의 결합으로 정상성 항상 만족 → 함수() 통해 q+1차항부터 절단 가능
(ARIMA)	. Autoregressive Integrated Moving Average . 자기회귀 + 이동평균 (비정상시계열) → 차분 통해 정상화 가능 . ARIMA (p, d, q) 형태로 표현 → p : 자기회귀(AR) 차수 / d : 차분 / q : 이동평균(MA) 차수 → 데이터 정상성 확보 위해 를 먼저 결정하고, p와 q 결정 - ARIMA (3, 2, 4) 모형에서 두 번 차분 시 모형 변환 가능 - ARIMA (0, 2, 4)는 (2, 4) 표현 가능 → 두 번 차분 시 (4) - ARIMA (3, 1, 0)은 (3, 1) 표현 가능 → 한 번 차분 시 (3)
법	. 일정 기간별 이동평균을 통해 추세 파악 후 다음 기간 데이터 예측 → 일정 기간의 관측치에 모두 동일 가중치 부여 (추세, 주기)
법	. 일정기간이 아닌 모든 시계열 자료를 사용해 평균 계산 . 단기간에 발생하는 불규칙한 변동 평활하는 방법 → 최근 관측치에 더 높은 가중치 부여 (최신 변동 민감)

- 분해시계열 : 시계열에 영향을 주는 요인을 시계열에서 분리해 분석하는 방법

요인	자료가 오르거나 내리는 추세, 선형, 이차식 형태, 지수적 형태
요인	고정된 주기(요일/월/분기)에 따른 자료의 변화
요인	알려지지 않은 주기로 자료가 변화 (경제, 사회적 요인)
요인	위 3가지 요인으로 설명할 수 없는 오차에 해당하는 요인

■ 데이터 마이닝

- 대용량 데이터 속에 의미 있는 패턴을 파악 및 예측하여 의사결정에 활용

[단계] 목적 설정 → 데이터 → 데이터 → 기법 적용 → 검증

(데이터 정제 / 충분한 규모)

모델링 기법에 따른 변수 정의 / SW 적용 가능하도록 적합한 형식 변환

- 데이터 분할 : 과대적합 및 과소적합 방지 / 불균형 데이터 문제 해결 목적

- . (Data - 50%) : 추정용 / 훈련용 데이터 → 마이닝 모델 생성 시 활용
- . (Data - 30%) : 모델의 과대/과소 적합 조정 시 활용
→ Overfitting 여부 및 Early Stopping 활용
- . (~ 20%) : 모델 성능 평가 시 활용

※ 분할 데이터 학습 방법

	. 데이터를 2 분류로 랜덤 구분 (훈련/train & 평가/test) → 훈련 데이터와 평가 데이터는 서로 중복 불가
교차검증	. 홀드아웃의 단점을 보완하여 데이터를 k개 집단으로 구분하고, k-1개 집단은 훈련용으로, 나머지 1개 집단은 검증용으로 활용 → k번 반복 검증하여 총 k개의 평가 결과의 평균값을 최종 선택
	. . 데이터 개수(n)만큼 학습 진행 → 1개 관측값만 검증용으로, 나머지 n-1개를 훈련용으로 사용 . 한정적인 데이터인 경우 / 새로운 데이터의 정확한 에러 예측
()	. 복원추출 방식으로 데이터를 구분 (데이터 양이 부족할 시 적합) . d번 반복 시행할 때 하나의 관측치가 선정되지 않을 확률 = $(1 - 1/d)^d$ → d가 충분히 클 경우: 36.8% → 전체 데이터의 63.2% : 훈련용 데이터로 지정



■ 분류 분석 종류

① 로지스틱 회귀분석 → 연결함수 : $\square$ 함수 ($\square$ function)

- 종속변수가 이산형(범주형) 데이터로 성공 또는 실패(1 또는 0)로 분류

$\square$	성공할 확률이 P 일 때, $\frac{\text{성공 확률}}{\text{실패 확률}} = \frac{P}{1-P} \rightarrow \text{오즈 (Odds)}$
$\square$	$\therefore \text{odds}$ 값에 $\log$ 취함 $\rightarrow \ln \text{odds} = \ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x_i$ $\rightarrow \frac{P}{1-P} = \exp(\beta_0 + \beta_1 x_i) \rightarrow \exp(\beta_0) \times \exp(\beta_1 x_i)$ $\rightarrow x_i$ 가 한 단위 증가할 때마다 성공의 오즈는 $\square$ 만큼 증가 $f(X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}} = \frac{1}{1 + e^{-\beta X}}$ ← $\square$ 함수 $\square$ 연속형 0~1 사이 값으로 변환 $\rightarrow$ 종속변수인 로짓(Logit)과 독립변수는 서로 선형관계 유지

- 계수 추정법: 최대우도추정법 / 모형 검증: 카이제곱 검증

- $\square$ ($\square$): 성공확률이 실패확률의 몇 배인지 나타내는 확률
2개 오즈의 비율

② $\square$ 나무

- 데이터 분류 기준을 의사결정 규칙으로 구성된 나무 구조로 나타내는 방법
- 새로운 데이터 분류 및 값 예측 목적 / 현재 분할은 이전 분할에 영향 받음
- 자식마디의 순수도 $\square$ 하도록 분류나무 형성 = 데이터 불순도 $\square$ 하는 방향
(분할 기준: 지니 지수 및 엔트로피 최소화, 카이제곱 통계량 활용)

[장점] 단순한 구조로 해석 용이 / 범주형 및 수치형 변수 모두 사용 가능
비모수적 모형 (가정 불필요) / 비정상적 잡음 데이터에 덜 민감 (가치치기)

[단점] 새로운 자료에 대한 과대적합 발생 가능 / 경계선 부근 자료값에 오차가 큼
예측변수 효과 및 중요도 파악 어려움

- ※ $\square$: 분리가 더 이상 일어나지 않는 규칙 → 과대적합 방지
- ※ $\square$: 불필요한 분기를 제거하여 모델의 일반화 성능 향상
(가치치기 비용함수 최소인 분기를 찾아 제거 → $\square$ 방식)

알고리즘	CART	C4.5 / C5.0	CHAID
분류형 (범주형)	$\square$ 지수	$\square$ 지수	$\square$ 통계량 또는 그 p-value
회귀형 (연속형)	분산 감소량		$\square$ 통계량 또는 그 p-value

* 낮을수록 순수도 증가: 지니 지수, 엔트로피 지수,
(파란색) 카이제곱 통계량 또는 ANOVA F-통계량의 p-value

* 높을수록 순수도 증가: 분산 감소량, 카이제곱 통계량, ANOVA F-통계량
(빨간색)

※ 불순도 측정 지수 (값이 낮을수록 높은 순수도)

. 지니 지수 = $\square$ (← 각 사건이 일어날 확률 제곱의 합)

. 엔트로피 지수 = $\square$

[예시] 영화가 게임에서 이길 확률 = 1/3, 게임에서 질 확률 = 2/3

- 지니 지수 = $1 - \square = 1 - 5/9 = 4/9$

- 엔트로피 지수 = $\square$

③ 이상발

- 여러 개의 분류 모형에 의한 예측 결과를 조합 (전체 분산 감소 → 성능 향상)
- 상호 연관성이 $\square$ 모형 결합 시 효과 극대화 / 과적합(overfitting) 감소 효과

$\square$ ($\square$)	. 각 모델 예측 결과 중 가장 많이 나온 결과를 최종 결과로 채택
$\square$	. 복원추출 기반 부트스트랩 자료 생성하여 각 모델 생성 각 모델이 $\square$ 학습 후 최종 결과를 보팅 방식으로 집계 → 같은 데이터가 중복 추출 가능 → 한번도 추출되지 않은 데이터도 존재 = 36.8%
$\square$	. 잘못 분류된 데이터에 가중치를 부여하여 표본 추출 ($\square$ 학습) → 이전 모델의 오차 보완 / 이상치(Outlier)에 민감 . 알고리즘: AdaBoost, GradientBoost, LightGBM, XGBoost
$\square$	. 배깅 방식에 복수의 의사결정 나무 사용 (과적합 방지 가능) → 해석이 어렵지만 예측력 및 정확도 높음 (이상치에 강함)

④ 인공신경망

- '입력층 / 은닉층(hidden layer) / 출력층'으로 구성 → 각 층에 $\square$ ($\square$) 존재
- 많은 변수가 존재하거나 복잡한 비선형관계 시 유용 / 잡음에 대해 민감하지 않음
- 결과에 대한 해석 어려움 / 적절한 은닉층 개수 필요 (초기 은닉층 개수 지정 어려움)
. 적은 은닉층: $\square$ 적합 발생 / 복잡한 모델 부적합
. 많은 은닉층: 복잡한 모델 구현 가능 / but, $\square$ 적합 및 $\square$ 문제 발생 가능

※ $\square$ 문제: 역전파 알고리즘에서 처음 입력층으로 진행할수록
기울기가 점차적으로 작아지다가 나중에는 거의 기울기의 변화가 없어지는 문제
→ 은닉층 노드의 가중치 업데이트 불가로 신경망에 대한 원활한 학습 어려움

. $\square$: 함수 기울기가 낮은 방향으로 점차 이동시켜
최종 기울기의 최소값(0)에 근접할 때까지 가중치를 반복 갱신

[활성화 함수]

- 인공신경망의 선형성 극복 방법
- 신경망 모형에서 입력 받은 데이터로부터 결과값을 출력할 때 사용하는 함수

$\square$	. 이진 분류문제 / 0 ~ 1 사이의 연속형 확률 (출력층의 노드가 1개인 경우 로지스틱과 동일)	$= \frac{1}{1 + e^{-a}}$
$\square$	. 복수의 출력값과 목표값이 다범주(다변)인 경우 활용 → 각 범주에 속할 사후 확률을 제공	$= \frac{e^{a_i}}{\sum_{i=1}^k e^{a_i}}$
$\square$	. -1부터 1 사이의 값 (중심값을 0으로 설정) . 시그모이드 함수의 느린 최적화 과정 개선	$= \frac{e^a - e^{-a}}{e^a + e^{-a}}$
$\square$	. 음수 입력값 = 0, 양수 입력값은 그대로 반영 → 기울기 소실 문제 해결 / 빠른 학습	$= \max(0, a)$
$\square$ 함수	. 입력값이 양수일 때 1을, 음수일 때는 0값 산출	-

⑤ SVM (Support Vector Machine, 서포트벡터머신)

- 데이터를 분류하거나 예측(회귀분석)하는 지도학습 알고리즘

. $\square$: 두 그룹 간 마진을 최대화로 나누는 결정 경계

. $\square$: 초평면과 가장 가까운 데이터 포인트


. $\square$: 초평면과 서포트벡터 사이의 거리

→ 마진이 클수록 신규 데이터에 대한 일반화 성능 향상

→ n차원의 데이터에서 $\square$ 차원의 초평면으로 분리

ex. 2차원 평면 데이터의 초평면은 1차원 선

3차원 공간 데이터의 초평면은 2차원 면



. 하드 마진: 모든 데이터가 결정경계 마진 밖으로 위치 (완벽한 선형 분리, 오류 허용 없음)

. 소프트 마진: 결정경계 마진 안에 데이터의 수를 제한적으로 허용 (오류 허용 가능)

※ $\square$ 기법: 선형으로 분리할 수 없는 비선형 데이터를 고차원 공간으로 매핑하여
선형 분리가 가능하게 해주는 기법 ($\square$ 차원 데이터 → $\square$ 차원 데이터로 변환)
→ 종류: 선형 / 다항식 / 가우시안 / 시그모이드 커널



※ k-NN (k-Nearest Neighbor) 알고리즘

- 특정 데이터를 k개의 인접한 요소를 기반으로 예측하는 기반 지도학습 분류
- 사전 학습 없이 새로운 데이터 분류 가능 (비선형 데이터에 유용한 알고리즘)
- 새로운 값은 기존의 데이터를 기준으로 가장 가까운 k개의 최근접 값을 분류
- 적절한 k값 선정 필요 (k값이 1에 가까우면 , k값이 클수록 문제 발생)



[분류모형 평가지표]

★ 오분류표

		예측 (H ₀)		
		True (P)	False (N)	
실제 (판정)	True		 (2종 오류)	실제 True인 것 중에서 모델이 True라 예측한 것의 비율 : = TP rate / Hit rate ↓ Sensitivity (Recall)
	False	 (1종 오류)		
		Precision 	Negative Predictive Value 	Specificity
			Accuracy 	

모델이 True라고 분류한 것 중에서
 실제 True인 것의 비율 :

* 실제와 예측 결과 동일 시 → T (True)
 실제와 예측 결과 다를 시 → F (False)

▶ F_β 지표 = $(\text{Precision} \times \text{Recall}) / (\beta^2 \times \text{Precision} + \text{Recall})$

β = 1일 때, Precision과 Recall의 평균 → $F1 \text{ score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$

β값을 통해 Recall(재현율)에 가중치 부여 가능


→ β 1 : Recall 낮은 비중 / Precision 높은 비중 (ex. $F_{0.5}$ = 2배 가중치)

→ β 1 : Recall 높은 비중 / Precision 낮은 비중 (ex. F_2 = 2배 가중치)

★ 커브

- x축을 FP rate (1-specificity), y축을 민감도 (Sensitivity = TP rate)로 시각화한 그래프
- 그래프의 밑면적이 넓을수록 (1에 가까울수록) 좋은 모델로 평가

그래프가 좌상단에 근접할수록
모델 성능 향상



★ 도표 (Lift Table)

- 임의로 나눈 각 등급별로 반응 검출율, 반응률, Gain(이득), Lift(향상도) 등의 정보를 산출하여 나타낸 도표
- 분류 모형의 예측 성능 평가를 위한 척도 / 불균형 데이터 집합에 주로 사용

★ 도표

- 이익(gain): 목표 범주에 속하는 개체들이 각 등급에 얼마나 분포하는지 나타낸 값
- 분류된 관측치가 각 등급별로 얼마나 포함되는지를 나타낸 도표
- 이익도표의 각 등급은 예측확률에 따라 매겨진 순위이기 때문에, 상위 등급에서는 더 높은 반응률을 보이는 것이 좋은 모형

- **군집 분석**: 각 개체의 유사성을 기준으로 서로 유사성이 높은 군집으로 분류하고 군집들 간에 관계를 분석하는 다변량분석 기법 (이질적인 모집단을 세분화)

▶ **계층적 군집** - 가장 유사한 개체를 분류하는 과정을 반복하여 군집 형성
유사성(거리)에 대한 정의 필요 / 군집 간 연결법

[거리 종류] - 연속형



	두 점의 최단 직선 거리 (제곱합에 대한 제곱근) $= \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2 + \dots}$
	두 점의 각 성분별 차의 절대값 합 $= a_1 - b_1 + a_2 - b_2 + \dots$
	변수 거리 차 중 최대값 $= \text{Max}(a_1 - b_1 , a_2 - b_2 , \dots)$
	거리 차수(p)와 함께 사용, 일반적으로 1 또는 2 사용 $D(x, y) = \left(\sum_{i=1}^n x_i - y_i ^p \right)^{\frac{1}{p}}$ p = 1 → 맨해튼 거리 p = 2 → 유클리드 거리
	변수의 표준화와 함께 변수 간의 상관관계(상관성)를 동시에 고려 $d(i, j) = \sqrt{(x_i - x_j)' S^{-1} (x_i - x_j)}$ * 표본 공분산행렬 $S = (S_{ij})_{p \times p}$
	각 변수를 표준편차로 변환 후 유클리드 거리로 계산 $d(i, j) = \sqrt{(x_i - x_j)' D^{-1} (x_i - x_j)}$ * 표본분산 대각행렬 $D = \text{Diag}(S_{11}, \dots, S_{pp})$

[거리 종류] - 범주형

유사도 similarity	두 데이터 집합 중 합집합에서 교집합의 비율 (0 ~ 1 사이 값) $J(A, B) = \frac{ A \cap B }{ A \cup B } = \frac{ A \cap B }{ A + B - A \cap B }$
유사도 similarity	두 벡터 사이의 사이각의 코사인값으로 유사도 측정 $\text{similarity} = \cos(\theta) = \frac{A \cdot B}{\ A\ \ B\ }$




▶ **계층적 군집 분석** → 반복 재분석 시에도 결과가 달라지지 않음

연결법	군집 간 개체들 중 가장 가까운 개체들의 거리 (= 연결법)
연결법	군집 간 개체들 중 가장 먼 개체들의 거리 (= 연결법)
연결법	두 군집의 중심 간의 거리
연결법	군집 간 모든 개체들 간의 거리 평균 (많은 계산량)
연결법	군집 내 오차제곱합(SSE)의 증가량을 최소화하는 방향으로 군집화 → 군집 내 편차는 작게, 군집 간 편차는 크게 (정보 손실 최소화)

★ (): 계층적 군집화를 시각화하여 직관적으로 표현

→ 기준선과 의 선이 교차하는 개수 = 해당 기준선에서의 군집의 개수





▶ **군집화 (군집화)** → '집단 내 제곱합 그래프'에 활용 가능

- k개의 군집으로 묶고 각 군집과 거리 차이의 분산을 최소화하는 방식

[장점] 단순한 알고리즘 / 빠른 처리속도 / 계층적 군집보다 많은 양의 데이터 처리

[단점] 잡음 및 이상값에 많은 영향 / 비선형(U자, S자형) 군집 존재 시 성능 저하
초기 군집 개수(k) 결정 어려움 / 결과 해석 난해함

[과정] ① 군집 개수(k) 설정 및 초기 중심점 설정

② 각 데이터를 가장 가까운 군집에 재할당

③ 각 군집 내 데이터들의 평균으로 군집의 중심 재설정

④ 군집 중심의 변화가 없을 때까지 ②, ③ 반복

※ 군집 : K-평균 군집화의 이상치 민감성 한계 극복 (ex. PAM)
→ 분석 전 이상값 제거 또는 중앙값 사용

► ()

- 밀도 기반으로 높은 밀도를 중심으로 군집화

→ 임의의 점 기준으로 반경 내에 n개 이상 존재 시 군집화

→ 가우시안 분포가 아닌 임의적 모양의 군집 분석에 적합

(k-means 군집화 보완 → 비선형(U자, S자형)의 분포 데이터도 해석 가능)

► ()

- 복잡한 형태의 분포를 단순한 형태의 분포들을 모아 선형 결합한 분포로 설명 가능

- 잠재변수(latent variable)가 존재하여 가능도를 직접 최대화시키기 어려움

→ 알고리즘 사용 ()

[과정] ① 모수(평균, 분산 등)에 대해 임의의 초기값 설정

② E-step : k 개의 군집에 대해 각 군집에 속할 기댓값 추정

③ M-step : 추정된 기댓값으로부터 확률분포의 모수를 갱신하고,
②번부터 다시 반복

▶ (, 자기 조직화 지도)

- 비지도 학습 / 차원축소와 군집화를 동시에 수행 (고차원 → 저차원 변환)

- 입력층과 2차원 구조의 경쟁층으로 구성 (은닉층 X)

- (전방 패스) 방식 (주의! 인공신경망에선 역전파 방식)

- 승자 독점 방식으로 경쟁층에는 입력값과 가장 유사한(가까운) 승자 뉴런만 출력
→ **BMU (Best Matching Unit)**

※ 군집 분석 평가 지표

 계수	. 개별 데이터가 같은 군집 내의 데이터와 얼마나 가까운지, 다른 군집 내 데이터와는 얼마나 멀리 분리되어 있는지 나타냄 →  부터  사이 값으로,  에 가까울수록 군집화 성능 우수
 	.  = 군집과 군집 사이 거리 중 최소값 군집 내 데이터들 거리 중 최대값 → DI 값이 클수록 군집화 성능 우수

■ 연관 분석

→ 마트에서 기저귀를 사는 사람은 맥주도 같이 산다!

- 항목들 간에 조건-결과로 이뤄진 패턴을 분석 (장바구니 분석 ex. 마케팅)

[장점] 조건 반응(If - then) 기반으로 분석 결과 명확한 이해 (비목적성 분석)

[단점] 분석할 품목 수가 증가하면 **계산량이 기하급수적으로 증가**

알고리즘	연관분석의 대표적 알고리즘 / 데이터 발생 빈도 기반 분석 지지도 / 신뢰도 / 향상도 지표 사용 → 데이터셋이 큰 경우 발생 가능한 모든 후보 항목 계산으로 처리속도 지연 (비효율) [알고리즘 수행 순서] ① 최소 설정 ② 개별 품목 중 최소 넘는 모든 품목 탐색 ②에서 찾은 개별 품목을 이용해 최소 를 넘는 품목 집합 탐색 ④ 반복적으로 수행하여 최소 가 넘는 품목집합 탐색
	. Apriori 단점 보완 / 구조화된 트리 사용 (FP-tree, node/link) → 대량의 데이터셋 처리 성능 우수 (빠른 처리속도)

★ 연관분석 측정지표

	· A와 B가 동시에 포함된 거래 비율 ▶ $A \rightarrow B$ = $P(A \cap B)$
	· A를 포함하는 거래 중 A와 B가 동시에 거래되는 비율 ▶ $A \rightarrow B$ = $P(B A) = \frac{P(A \cap B)}{P(A)}$
	· A가 구매되지 않았을 때 B의 구매확률에 비해, A가 구매되었을 때 B의 구매확률 증가 비율 ▶ $A \rightarrow B$ = $\frac{P(B A)}{P(B)} = \frac{P(A \cap B)}{P(A) \times P(B)}$ > 1 : 양의 상관성 = 1 : 상관성 X (독립) < 1 : 음의 상관성

※ : 두 단계의 학습으로, 첫 단계는 다양한 기본 모델을 사용한 학습이고, 두 번째 단계는 첫 단계에서 얻은 결과를 입력으로 하는 메타 모델 학습

※ **알고리즘**: 생물학적 진화 과정을 모방하여 최적화 및 검색 문제를 해결하는데 사용되는 계산 알고리즘
다양한 해를 탐색하고 선택, 교차, 변이와 같은 유전 연산을 통해 최적의 해를 찾는 데 효과적인 알고리즘



■ Summary 함수 해석

[예시-1]

	weight	feed
Min.	:107.0	casein :7
1st Qu.	:198.5	horsebean :8
Median	:248.2	linseed :10
Mean	:261.3	meatmeal :9
3rd Qu.	:375.5	soybean :15
Max.	:442.8	sunflower :4

- . Weight는 데이터, Feed는 데이터
- . Weight의 평균() = / 중앙값() =
- Weight는 쪽으로 꼬리가 길게 늘어져 있다 = 왜도가 0보다 (Median < Mean)
- . Weight에서 198.5보다 작은 값은 전체의 %이다. (Q1 =)
- . Weight에서 375.5보다 큰 값은 전체의 %이다. (Q3 =)
- 375.5보다 작은 값은 전체의 %이다.
- . Weight의 전체 데이터 범위는 최소 에서 최대 이다.
- . Feed의 총 데이터 수는 이다 (= 모든 범주별 데이터 수의 합)
- . Feed 중 casein에 해당되는 데이터는 개 / soybean 개수가 가장 많다.

[예시-2]

```
data("chickwts")
> t_weight <- t.test(x=chickwts$weight, mu=60)
> t_weight

One sample t-test
data: chickwts$weight
t = 0.1847, df = 49, p-value = 0.75
alternative hypothesis: true mean is not equal to 60
95 percent confidence interval:
 55.9535 66.8965
sample estimates:
mean of x
61.425
```

- . : weight 평균이 60이다 / : weight 평균이 60이 아니다
- One sample T-test
- . 전체 관측치의 수는 개이다. → $n = \text{} + 1 = 49 + 1$
- 만약 Two sample T-test 였다면 $n = Df + \text{}$
- . p-value 값이 0.75이므로 유의수준 보다 높아 귀무가설은 기각되지 않는다.
- . weight 95% 신뢰구간은 ~ 이다.
- 귀무가설에서 제시한 평균 60은 95% 신뢰구간에 속한다.
- . 실제 weight의 점추정량(평균)은 이다.

[예시-3]

```
> t.test(extra~group, data=sleep, var.equal=TRUE)

Two sample t-test

data: extra by group
t = 1.2492, df = 8, p-value = 0.2469
alternative hypothesis: true difference in mean is not equal to 0
95 percent confidence interval:
 -1.319829 4.439829
sample estimates:
mean in group 1 mean in group 2
 52.66 51.10
```

- . : 두 그룹 간 평균이 같다 / : 두 그룹 간 평균이 다르다
- two sample T-test
- . 전체 관측치의 수는 개이다. → $n = \text{} + 2 = 8 + 2$
- . p-value 값이 0.2469이므로 유의수준 보다 높아 귀무가설은 기각되지 않는다.
- 두그룹 간 평균은 유의미하게 다르지 않다.
- . 두 그룹의 평균값 차이가 95% 확률로 ~ 사이에 존재한다.
- . 그룹1의 평균: / 그룹2의 평균:

[예시-4]

```
Call:
lm(formula = weight ~ time, data = chickweight)

Residuals:
    Min       1Q   Median       3Q      Max
-138.331  -14.536    0.926   13.533   160.669

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  27.4674    3.0365   9.046  <2e-16 ***
Time         8.8030    0.2397  36.725  <2e-16 ***

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 38.91 on 576 degrees of freedom
Multiple R-squared:  0.7007, Adjusted R-squared:  0.7002
F-statistic: 1349 on 1 and 576 DF, p-value: <2.2e-16
```

- . 독립변수: / 종속변수: → 회귀분석 모형
- . R-squared (결정계수) 값: → 종속변수 weight의 설명력
- . 해당 회귀분석 모형에서 추정한 선형 회귀식
- ▶ $\text{weight} = \text{} * \text{time} + \text{}$
- Time 변수 1증가할 때마다 weight의 평균 증가량은
- . 의 p-value 값: < 2e-16 → 0.05 보다 작으므로 유의수준 5% 하에서 유의함
- . 의 p-value 값: < 2.2e-16 → 0.05 보다 작으므로 위 회귀모형은 유의함

[예시-5]

```
Call:
lm(formula = addict ~ age + height + grade, data = phone)

Residuals:
    Min       1Q   Median       3Q      Max
-10.0943  -2.5127  -0.0868   2.4674   9.7259

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  9.3518    2.1193   4.413  1.56e-16 ***
age          0.1404    0.0594   2.362   0.029 *
height      -0.0055    0.0339  -0.165   0.758
grade       -0.1286    0.0148  -8.690  2.2e-14 ***

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.542 on 100 degrees of freedom
Multiple R-squared:  0.3043, Adjusted R-squared:  0.2953
F-statistic: 33.97 on 3 and 96 DF, p-value: <2.2e-16
```

- . 독립변수: age, height, grade 총 3개 / 종속변수: → 다중회귀분석
- . 전체 표본의 수는 개이다. → $n = \text{} + \text{} + 1 = 96 + 3 + 1$
- . 해당 회귀분석 모형에서 추정한 선형 회귀식
- ▶ $\text{addict} = \text{} * \text{age} - \text{} * \text{height} - \text{} * \text{grade} + \text{}$
- age(나이)가 높을수록, grade(성적)이 낮을수록 addict(핸드폰 중독)은 높아짐
- . age와 grade의 p-value 값은 0.05 보다 작아 유의수준 5%에서 통계적으로 유의함
- . 는 p-value 값이 0.05 보다 높아 종속변수(addict)와 통계적으로 유의하지 않음
- . 다중 결정계수 (Multiple R-squared):
- . 수정된 결정계수 (Adjusted R-squared): (해당 모델의 설명력 %)
- 목적: 단순히 독립변수 개수가 증가함에 따라 결정계수도 증가하는 한계를 보완 (무의미한 독립변수 추가만으로도 결정계수 값이 증가할 우려 존재)
- 이에 따라 독립변수 개수를 고려하여 보정된 자유도로 '수정된 결정계수' 산출
- 독립변수 개수가 많아지면 수정된 결정계수 값이 다중 결정계수보다 작아짐
- . F-통계량의 p-value 값: < 2.2e-16 → 0.05 보다 작으므로 위 회귀모형은 함